

ChatEval: fino a che punto gli LLM possono replicare i giudizi umani nella valutazione dei testi?

Progetto Intelligenza Artificiale 2024/2025

Genovese Ludovica (052251743) e Sica Manuel (0522501870)

Contents

1	Introduzione	2
2	Metodologia	2
2.1	Metriche utilizzate per la valutazione dei risultati	3
2.2	Dataset utilizzato	3
2.3	Modifiche al codice di ChatEval	4
2.4	Modelli utilizzati nel framework	5
3	Esperimenti e Risultati	5
4	Conclusioni	6
4.1	Sfide Affrontate nell'Implementazione	6
4.2	Analisi delle Metriche	7
4.3	Limitazioni	7

1 Introduzione

Con l'avvento e la crescente diffusione dei Large Language Models (LLM) negli ultimi anni, sorge sempre più spontanea la domanda se questi possano in qualche modo eguagliare le capacità cognitive degli esseri umani. In questo contesto, Chan et al. [1] hanno sviluppato ChatEval, un framework progettato per esplorare il potenziale degli LLM nella valutazione cooperativa dei testi. La domanda centrale che ci poniamo è: *sono gli LLM in grado di valutare testi allo stesso modo di un essere umano?*

ChatEval consente a più agenti di discutere determinati testi attraverso diverse strategie di comunicazione, con l'obiettivo di raggiungere giudizi finali che siano il più possibile simili a quelli umani. Ogni agente si concentra su prospettive specifiche, apportando punti di vista differenti e competenze eterogenee, in modo da garantire una valutazione su più livelli e cogliere dettagli che potrebbero sfuggire a una singola prospettiva. Questo processo avviene attraverso un continuo scambio di opinioni, in cui gli agenti, confrontandosi tra loro, riescono a identificare aspetti nuovi e a riconsiderare i propri giudizi iniziali alla luce delle argomentazioni altrui, proprio come avverrebbe un processo decisionale collaborativo tipico di due persone.

In particolare, vengono utilizzati i seguenti componenti principali:

- **Debater Agents:** Ogni LLM viene identificato come un agente. Questo ha il compito di generare la propria risposta in base al prompt che gli è stato dato. Le risposte degli altri agenti vengono trattate come cronologia della chat, creando un ambiente di discussione continuo.
- **Diverse Role Specification:** Il prompt specificato assegna un 'ruolo' all'agente in questione, descrivendo una vera e propria personalità che il modello deve assumere quando deve generare la sua risposta. Questo approccio consente di simulare una varietà di prospettive critiche, riducendo i bias e aumentando la diversità delle valutazioni.
- **Communication Strategy:** Vengono implementate tre diverse strategie di comunicazione con cui avvengono le discussioni tra gli agenti:
 - **One-By-One:** Durante ogni turno del dibattito, gli agenti generano le loro risposte a turni, basandosi sull'osservazione corrente. Questo approccio favorisce un'elaborazione sequenziale delle idee, riducendo il rischio di influenze reciproche immediate.
 - **Simultaneous-Talk:** Gli agenti generano risposte in modo asincrono, riducendo l'influenza dell'ordine delle risposte. In questo modo, ogni agente fornisce la propria valutazione senza essere influenzato direttamente dai giudizi precedenti.
 - **Simultaneous-Talk with Summarizer:** Viene introdotto un altro LLM che ha il ruolo di 'riassumere' i messaggi generati fino a quel momento. Questo summarizer funge da mediatore, sintetizzando le opinioni per fornire una base comune agli agenti nelle iterazioni successive.




Figure 1: Strategie di Comunicazione implementate da ChatEval

2 Metodologia

Il nostro obiettivo si propone di valutare l'efficacia del framework ChatEval applicato a un dataset di natura diversa rispetto a quelli tradizionalmente utilizzati. In particolare, ci siamo focalizzati sulle capacità di ChatEval di replicare le dinamiche dei giudizi umani andando a valutare contesti di dialogo *open-domain*, verificando se fosse in grado di mantenere una coerenza valutativa paragonabile a quella umana.

2.1 Metriche utilizzate per la valutazione dei risultati

Per raggiungere questo obiettivo, abbiamo eseguito ChatEval su un nuovo dataset preso da ConvAI e calcolato specifiche metriche di correlazione, tra cui **Spearman**, **Pearson** e **Kendall-Tau** utili nel misurare l'allineamento tra i suoi giudizi e quelli umani:

- **Spearman**: misura la correlazione tra due variabili basandosi sui ranghi delle osservazioni piuttosto che sui valori assoluti.

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

- **Pearson**: valuta la correlazione lineare tra due serie di dati, misurando la forza e la direzione della relazione lineare tra le variabili.

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

dove:

- $r = 1$ indica una correlazione lineare positiva perfetta,
- $r = -1$ indica una correlazione lineare negativa perfetta,
- $r = 0$ indica assenza di correlazione lineare.

- **Kendall-Tau**: fornisce una misura della concordanza tra due insiemi di dati, basata sul numero di coppie ordinate in modo concordante o discordante.

$$\tau = \frac{(C - D)}{\frac{1}{2}n(n - 1)}$$

dove:

- C è il numero di coppie concordanti, ovvero se $(x_i - x_j)(y_i - y_j) > 0$,
- D è il numero di coppie discordanti, ovvero se $(x_i - x_j)(y_i - y_j) < 0$,
- n è il numero totale di osservazioni.

2.2 Dataset utilizzato

Il dataset analizzato è composto da 1417 dialoghi estratti dal benchmark ConvAI, ciascuno strutturato per rappresentare scambi conversazionali tra due partecipanti. Il primo passo è stato l'adattamento del dataset, necessario per renderlo compatibile con la struttura richiesta da ChatEval.

<pre>{ "dialog_id": "0x595b21f9", "dialog": [{ "id": 0, "sender": "participant2", "text": "" }, { "id": 1, "sender": "participant2", "text": "" }], "bot_profile": [""], "user_profile": [""], "eval_score": 2, "profile_match": 1 }</pre>		<pre>[{ "question_id": 1, "question": "?", "response": { "participant1": "", "participant2": "" } }]</pre>	Ogni
--	--	--	------

dialogo presenta una struttura standardizzata che facilita l'analisi delle interazioni e l'applicazione delle metriche di correlazione con i giudizi umani. L'idea alla base di questa ristrutturazione è stata quella di **accorpare tutte le battute del dialogo** all'interno dell'elemento **response**, specificando chiaramente quale partecipante pronuncia ciascuna battuta. Inoltre, la prima battuta del dialogo è stata utilizzata come **question**, così avendo la prima domanda come 'inizio' dell'intero dibattito, come se fosse la vera prima domanda.

```
[
{
  "question_id": "0x6beff65b",
  "question": "*same as participant2_0*",
  "response": {
    "participant2_0": "",
    "participant1_1": "",
    "participant2_2": "",
    .
    .
    .
  }
}
]
```

2.3 Modifiche al codice di ChatEval

Questa ristrutturazione ha comportato una **modifica al codice originale** del framework, in particolare al file `llmeval.py`. È stato necessario adattare le sezioni di codice che precedentemente si concentravano esclusivamente sull'identificazione delle uniche due battute dei modelli GPT-3.5 e Vicuna. Le modifiche hanno permesso di estendere la logica di parsing per includere **tutte le battute** dei partecipanti `participant1` e `participant2`, garantendo così che l'intero dialogo venisse analizzato e valutato in modo completo da ChatEval.

```
for agent_id in range(len(agentverse.agents)):
    agentverse.agents[agent_id].source_text = ins["question"]

    participant1_responses = [v for k, v in ins["response"].items() if k.startswith("participant1")]
    participant2_responses = [v for k, v in ins["response"].items() if k.startswith("participant2")]

    agentverse.agents[agent_id].compared_text_one = " ".join(participant1_responses)
    agentverse.agents[agent_id].compared_text_two = " ".join(participant2_responses)

    agentverse.agents[agent_id].final_prompt = ""

agentverse.run()

evaluation = get_evaluation(settings="every_agent", messages=agentverse.agents[0].memory.messages, agent_nums=len(agentverse.agents))

evaluation_data = {
    "question": ins["question"],
    "response": {
        "participant1": " ".join(participant1_responses),
        "participant2": " ".join(participant2_responses)
    },
    "evaluation": evaluation
}

pair_comparison_output.append(evaluation_data)
```

Figure 2: Modifica al codice `llmeval.py` per adattarlo a leggere tutte le battute effettuate dai due participant (e non quelle di gpt35 e vicuna)

Inoltre, sono stati modificati i file `config.yaml` per configurare le diverse **strategie di comunicazione**, tra cui *One-By-One*, *Simultaneous-Talk* e *Simultaneous-Talk with Summarizer*, necessari per svolgere i vari test alla fine.

```
environment:
  env_type: llm_eval
  max_turns: 4
  rule:
    order:
      type: concurrent
    visibility:
      type: all
    selector:
      type: basic
    updater:
      type: basic
    describer:
      type: basic
```

Figure 3: Parametri per la strategia 'One-By-One'

```
environment:
  env_type: llm_eval
  max_turns: 4
  rule:
    order:
      type: sequential
    visibility:
      type: all
    selector:
      type: basic
    updater:
      type: basic
    describer:
      type: basic
```

Figure 4: Parametri per la strategia 'Simultaneous'

```
environment:
  env_type: llm_eval
  max_turns: 4
  rule:
    order:
      type: concurrent
    visibility:
      type: all
    selector:
      type: basic
    updater:
      type: basic
    describer:
      type: basic
    summarizer:
      enabled: true
      model: "gpt-4o-mini"
      llm_type: gpt-4o-mini
      temperature: 0
      max_tokens: 512
```

Figure 5: Parametri per la strategia 'Simultaneous with Summarizer'

2.4 Modelli utilizzati nel framework

Il tipo di Large Language Model generativo utilizzato è stato **GPT-4o-mini**. La scelta iniziale di GPT-4o-mini è stata motivata dal fatto che fosse uno dei modelli compatibili con il framework di GPT4All. Tuttavia, le richieste necessarie per l'utilizzo del framework si sono rivelate superiori alle capacità offerte, costringendoci a passare all'API ufficiale di OpenAI per completare i test. Nonostante questo cambiamento, abbiamo mantenuto GPT-4o-mini come modello principale per la sua **estrema flessibilità** e **costo contenuto**.

3 Esperimenti e Risultati

I dataset utilizzati per l'analisi consistono in 7 dialoghi selezionati casualmente dal nostro dataset di ConvAI. Per ciascuno di questi dialoghi, è stato generato l'output dei punteggi (scores) relativi a ognuna delle tre strategie di comunicazione implementate: *One-By-One*, *Simultaneous-Talk* e *Simultaneous-Talk with Summarizer*.

Esempi rappresentativi degli output generati possono essere consultati nell'**Appendice A**, dove sono riportati i risultati delle valutazioni effettuate dagli agenti per ciascuna strategia.

Considerando che ChatEval consente agli agenti di modificare le proprie valutazioni durante il dibattito, si è ritenuto opportuno adottare un criterio specifico per il confronto con l'**evalscore**. In particolare, per ogni strategia di comunicazione, sono stati considerati solo gli ultimi due punteggi assegnati ai due agenti, ritenuti i più rappresentativi delle valutazioni finali. La media di questi punteggi finali è stata calcolata per ottenere un unico valore complessivo, utilizzato per confrontare in modo diretto e significativo i risultati generati da ChatEval con i giudizi umani (**evalscore**).

One-By-One		Simultaneous		Sim. with Summarizer	
ChatEval Score	Eval Score	ChatEval Score	Eval Score	ChatEval Score	Eval Score
5.25	4	4.75	4	4.50	4
6.00	4	6.50	4	6.50	4
4.00	4	3.75	4	5.00	4
4.50	3	4.00	3	4.50	3
5.25	4	4.50	4	4.00	4
3.25	2	3.00	2	3.00	2
5.50	3	5.50	3	5.50	3

Dopo aver calcolato la media dei punteggi finali, è stato necessario procedere con la **normalizzazione dello score** per garantire la comparabilità tra i risultati di ChatEval e i giudizi umani. Infatti, mentre ChatEval restituisce valori compresi tra 1 e 10, l'**eval_score** umano utilizza una scala da 1 a 5. Per uniformare le due scale, i punteggi finali di ChatEval sono stati divisi per 2, consentendo così un confronto diretto e coerente tra le valutazioni automatiche e quelle umane.

One-By-One		Simultaneous		Sim. with Summarizer	
ChatEval Score	Eval Score	ChatEval Score	Eval Score	ChatEval Score	Eval Score
2.62	4	2.38	4	2.25	4
3.00	4	2.35	4	3.25	4
2.00	4	1.88	4	2.50	4
2.25	3	2.00	3	2.25	3
2.62	4	2.25	4	2.00	4
1.75	2	1.50	2	1.50	2
2.75	3	2.75	3	2.75	3

Di seguito il calcolo delle metriche di cui abbiamo discusso prima:

One-By-One		Simultaneous		Sim. with Summarizer	
Metric	Value	Metric	Value	Metric	Value
Spearman	0.81	Spearman	0.90	Spearman	0.81
Pearson	0.81	Pearson	0.90	Pearson	0.91
Kendall-Tau	0.74	Kendall-Tau	0.82	Kendall-Tau	0.74

Il codice sorgente del progetto [2], comprensivo delle modifiche effettuate per adattare ChatEval alla valutazione di dialoghi multi-turno, è disponibile su GitHub al seguente link:
<https://github.com/ludovic4g/ChatEval>

4 Conclusioni

4.1 Sfide Affrontate nell'Implementazione

Durante l'adattamento di ChatEval per la valutazione di dialoghi multi-turno, sono emerse diverse sfide tecniche e metodologiche che hanno richiesto modifiche sostanziali al framework.

- **Struttura del Dataset:** Il dataset ConvAI, progettato per conversazioni multi-turno, non era direttamente compatibile con ChatEval, che inizialmente valutava solo risposte singole. È stato quindi necessario ristrutturare i dati, accorpendo i turni di dialogo in un unico elemento **response**, identificando chiaramente i partecipanti e utilizzando la prima battuta del dialogo come **question** per preservare la coerenza del framework.
- **Parsing e Valutazione:** Il codice di `llm_eval.py` era progettato per analizzare solo due risposte, limitando la capacità del framework di gestire conversazioni complete. Per superare questa limitazione, il parsing è stato modificato per estrarre e valutare tutte le battute di `participant1` e `participant2`, garantendo una gestione più efficace dell'interazione tra agenti e adeguando il comportamento delle strategie di comunicazione *One-By-One*, *Simultaneous-Talk* e *Simultaneous-Talk with Summarizer*. Inoltre nel calcolo delle metriche, il Kappa di Cohen è stato un'altra metrica considerata ma lavorando principalmente con dati discreti, a differenza dei valori continui del nostro caso, abbiamo deciso di non tenerla in considerazione.
- **Criticità del Summarizer:** L'integrazione del Summarizer ha evidenziato alcuni problemi. In molti casi, ha mostrato una **tendenza alla ripetizione dei giudizi**, riducendo la diversità delle valutazioni. Inoltre, il processo di sintesi non sempre identificava i punti chiave della discussione, causando una perdita di informazioni importanti. In alcuni scenari, invece di migliorare la qualità delle valutazioni, il Summarizer amplificava errori presenti nelle risposte originali.

- **Limiti Computazionali e Utilizzo di API:** L’iniziale utilizzo di GPT-4o-mini con il framework **GPT4All** [3] ha evidenziato difficoltà nella gestione delle richieste, poiché il numero di chiamate superava i limiti previsti dal sistema. Per superare questo problema, è stato necessario passare all’API ufficiale di OpenAI, sacrificando parte della flessibilità del framework ma garantendo una maggiore stabilità nelle risposte. La scelta di GPT-4o-mini è stata comunque mantenuta per il suo costo contenuto rispetto a modelli più avanzati come GPT-4.

Queste sfide hanno evidenziato le complessità nell’adattare un sistema di valutazione automatica come ChatEval a dataset di dialoghi multi-turno. Il lavoro svolto ha permesso di superare diversi ostacoli, ma ha anche mostrato la necessità di miglioramenti futuri per rendere il framework più efficiente, adattabile e in grado di gestire in modo più avanzato la diversità delle valutazioni.

4.2 Analisi delle Metriche

Dall’analisi delle metriche emergono alcune osservazioni interessanti:

- La strategia **Simultaneous-Talk (Concurrent)** ha ottenuto le migliori performance in termini di correlazione, con valori di **Spearman** ($\rho = 0.896$), **Pearson** ($r = 0.898$), e **Kendall-Tau** ($\tau = 0.817$). La discussione asincrona tra gli agenti favorisce una valutazione più simile a quella umana e ha mostrato che questa strategia produce valutazioni più coerenti e meno influenzate da bias introdotti da valutazioni precedenti.
- La strategia **One-by-One (Sequential)** e la **Simultaneous-Talk with Summarizer** hanno mostrato risultati simili in termini di **Spearman** ($\rho = 0.809$) e **Kendall-Tau** ($\tau = 0.742$), ma la presenza del summarizer ha leggermente migliorato la correlazione lineare di **Pearson** (da $r = 0.814$ a $r = 0.908$), pertanto riducendo varianza all’interno delle risposte. Tuttavia, nei dialoghi analizzati, si è notato che il summarizer tende a introdurre una certa ridondanza nelle valutazioni.

4.3 Limitazioni

- **Bias nelle valutazioni ripetitive:** Sia nella strategia **Concurrent** che in quella con **Summarizer**, si è osservata una tendenza a ripetere giudizi simili, riducendo la diversità delle valutazioni. Inoltre, nei test effettuati, sono emersi problemi specifici con l’uso del summarizer: in alcuni casi, il summarizer ha introdotto ridondanza nelle valutazioni e ha mostrato difficoltà nel sintetizzare efficacemente i punti chiave emersi durante il dibattito, riducendo la variabilità dei giudizi e non riuscendo a evidenziare adeguatamente le differenze qualitative tra le risposte degli agenti.
- **Limiti legati al tipo di dataset:** La semplicità e la struttura poco articolata del dataset possono aver influenzato negativamente la capacità degli agenti di fornire valutazioni approfondite. In particolare, la presenza di domande e risposte brevi o incoerenti ha limitato l’analisi di aspetti complessi come la coerenza del discorso e la profondità delle risposte.

Possiamo concludere che gli LLM hanno una base molto promettente nel valutare testi in modo molto simile a quello umano, ma non riescono ancora a replicare completamente la loro complessità. Difatti già vedendo in particolare il **Simultaneous-Talk**, questo mostra una buona capacità di emulare i processi cognitivi umani e il modo in cui essi decidono i vari giudizi. Tuttavia, le limitazioni riscontrate, come la ridondanza nelle valutazioni, le difficoltà del summarizer nella sintesi delle discussioni e la sensibilità alla struttura del dataset, evidenziano un eventuale miglioramento da fare su certi aspetti.

Appendice A: Esempi di Output di ChatEval

In questa sezione vengono riportati alcuni output generati da ChatEval per diverse strategie di comunicazione. Questi esempi illustrano il processo di valutazione e i punteggi assegnati dai diversi agenti.

Esempio 1: Strategia Concurrent

```
02/10/2025 13:18:49 - INFO - httpx - HTTP Request: POST
  https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/10/2025 13:18:50 - INFO - httpx - HTTP Request: POST
  https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/10/2025 13:18:50 - INFO - root - General Public: After reviewing both responses, I
  find that Assistant 2 provides a more coherent and relevant answer to the user's
  question. While both assistants mention their interest in rap music and love for
  pizza, Assistant 2 maintains a clearer structure and offers more detail about
  their work and living situation.
```

Assistant 1's response is somewhat disjointed and includes irrelevant comments, such as "Wow you are sexy," which detracts from the overall helpfulness and relevance.

Overall, I would rate Assistant 2 higher for its clarity and relevance.

****Scores:****

- Assistant 1: 4/10

- Assistant 2: 7/10

```
02/10/2025 13:18:50 - INFO - root - Critic: It seems that both Assistant 1 and
  Assistant 2 provided responses that were somewhat disjointed and lacked coherence.
```

Assistant 1's response was more conversational but veered off-topic with personal questions that may not be relevant to the original question. It also included some awkward phrasing, such as "Wow you are sexy," which is inappropriate and detracts from the overall quality.

Assistant 2's response, while more focused on work and personal interests, was repetitive and included conflicting statements about being an electrician and a plumber. This inconsistency affects the clarity and reliability of the information provided.

In terms of helpfulness and relevance, both responses could be improved significantly. I would rate Assistant 1 a 4/10 for its conversational tone but inappropriate comments, and Assistant 2 a 5/10 for being slightly more relevant but lacking clarity and consistency.

Overall, I suggest that both assistants should aim for more coherent and relevant responses that directly address the user's question without unnecessary personal inquiries or contradictions.

```
02/10/2025 13:18:52 - INFO - httpx - HTTP Request: POST
  https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/10/2025 13:18:52 - INFO - httpx - HTTP Request: POST
  https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/10/2025 13:18:52 - INFO - root - General Public: It seems like there was no
  additional input or question. If you have any further thoughts or need assistance
  with something else, feel free to share!
02/10/2025 13:18:52 - INFO - root - Critic: It seems there was no additional input or
  question. If you have any further thoughts or need clarification on the
  evaluations of the assistants, feel free to share! I'm here to help.
02/10/2025 13:18:54 - INFO - httpx - HTTP Request: POST
  https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/10/2025 13:18:54 - INFO - httpx - HTTP Request: POST
  https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/10/2025 13:18:54 - INFO - root - General Public: Evaluation evidence: In
  evaluating the responses, Assistant 1's answer was more conversational but
  included irrelevant and inappropriate comments, which detracted from its overall
  quality. It lacked coherence and did not provide substantial information related
  to the user's question. On the other hand, Assistant 2's response was more
  structured and focused on relevant topics, such as work and personal interests,
```


although it contained some repetitive and conflicting statements about job roles. Overall, Assistant 2 provided a more relevant and coherent response, making it the stronger of the two.

The score of Assistant 1: 3

The score of Assistant 2: 6

02/10/2025 13:18:54 - INFO - root - Critic: Evaluation evidence: Upon reviewing both responses, Assistant 1's answer is characterized by a lack of coherence and relevance. It includes unrelated personal comments and questions that do not contribute to the conversation, making it feel disjointed. In contrast, Assistant 2 provides a more structured response, discussing their work and living situation, although it suffers from some repetition and inconsistency regarding their profession. Overall, Assistant 2's response is more relevant and informative, despite its flaws.

The score of Assistant 1: 3

The score of Assistant 2: 6

02/10/2025 13:18:57 - INFO - httpx - HTTP Request: POST

https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"

02/10/2025 13:18:59 - INFO - httpx - HTTP Request: POST

https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"

02/10/2025 13:18:59 - INFO - root - General Public: Evaluation evidence: In evaluating the responses, Assistant 1's answer was conversational but included irrelevant and inappropriate comments, such as "Wow you are sexy," which detracted from its overall quality and coherence. It also failed to provide substantial information related to the user's question. In contrast, Assistant 2's response was more structured and focused on relevant topics, such as work and personal interests, although it contained some repetitive statements about job roles. Overall, Assistant 2 provided a more relevant and coherent response, making it the stronger of the two.

The score of Assistant 1: 3

The score of Assistant 2: 6

02/10/2025 13:18:59 - INFO - root - Critic: Evaluation evidence: In evaluating the responses, Assistant 1's answer is characterized by a lack of coherence and relevance. It includes irrelevant personal comments and questions that detract from the overall quality and focus of the response. The conversational tone is overshadowed by inappropriate remarks, making it less suitable for the context. On the other hand, Assistant 2 provides a more structured and relevant response, discussing their work and personal interests. However, it suffers from some repetition and conflicting statements about their profession, which affects clarity. Overall, Assistant 2 is more informative and relevant, making it the stronger response.

The score of Assistant 1: 3

The score of Assistant 2: 6

=====instance 0=====

Esempio 2: Strategia Sequential

02/09/2025 18:18:28 - INFO - httpx - HTTP Request: POST

https://api.gpt4-all.xyz/v1/chat/completions "HTTP/1.1 200 OK"

02/09/2025 18:18:28 - INFO - root - General Public: After reviewing both responses, I find that Assistant 2 provides a more coherent and relevant answer to the user's question. While both assistants mention their interest in rap music and pizza, Assistant 2 maintains a clearer structure and provides more consistent information about their work and living situation.

Assistant 1's response is somewhat disjointed and includes irrelevant comments, such as "Wow you are sexy," which detracts from the overall helpfulness and relevance.

Overall, I would rate Assistant 2 higher for its clarity and relevance, giving it a score of 7, while I would rate Assistant 1 a score of 4 due to its lack of coherence and focus.

02/09/2025 18:18:29 - INFO - httpx - HTTP Request: POST

https://api.gpt4-all.xyz/v1/chat/completions "HTTP/1.1 200 OK"

02/09/2025 18:18:29 - INFO - root - Critic: It seems there was no follow-up or additional input. If you have any further questions or need clarification on my

assessment of the two AI assistants, feel free to ask!

```
02/09/2025 18:18:32 - INFO - httpx - HTTP Request: POST
https://api.gpt4-all.xyz/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 18:18:32 - INFO - root - General Public: Evaluation evidence: In
evaluating the responses, Assistant 2 demonstrates a more structured and relevant
approach to the user's question. It maintains a consistent theme throughout its
response, discussing music preferences, work, and living situation in a coherent
manner. In contrast, Assistant 1's response is fragmented and includes irrelevant
comments that detract from the overall quality, such as personal compliments and
disjointed questions. This lack of focus makes Assistant 1's response less helpful
and engaging. Therefore, Assistant 2 is rated higher for its clarity and relevance.
```

The score of Assistant 1: 4
The score of Assistant 2: 7

```
02/09/2025 18:18:34 - INFO - httpx - HTTP Request: POST
https://api.gpt4-all.xyz/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 18:18:34 - INFO - root - Critic: Evaluation evidence: Upon evaluation,
Assistant 1's response is characterized by a lack of coherence and relevance. It
includes unrelated personal comments and abrupt shifts in topics, which detracts
from its helpfulness. In contrast, Assistant 2 presents a more structured reply,
providing specific details about work and personal interests, which makes it
easier for the user to engage. Additionally, Assistant 2 maintains a consistent
flow of conversation, offering a clearer picture of its background and
preferences. Based on these observations, Assistant 2 is the stronger response
overall.
```

The score of Assistant 1: 3
The score of Assistant 2: 7

=====instance 0=====

Esempio 3: Strategia Simultaneous with Summarizer

=====instance 0=====

```
02/09/2025 22:00:53 - INFO - httpx - HTTP Request: POST
https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 22:00:54 - INFO - httpx - HTTP Request: POST
https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 22:00:54 - INFO - root - General Public: After reviewing both responses, I
find that Assistant 2 provides a more coherent and structured answer. While both
assistants mention their interest in rap music and love for pizza, Assistant 2
maintains a clearer narrative about their work and living situation.
```

Assistant 1's response is more disjointed, with abrupt shifts in topics and questions that don't flow well. It also includes some irrelevant comments, such as "Wow you are sexy," which detracts from the overall helpfulness and relevance of the response.

In terms of helpfulness, relevance, and clarity, I would rate Assistant 2 higher.

Overall, I would give Assistant 2 a score of 7 and Assistant 1 a score of 4.

```
02/09/2025 22:00:54 - INFO - root - Critic: It seems that both Assistant 1 and
Assistant 2 provided responses that were somewhat disjointed and lacked coherence.
```

****Assistant 1**:**

- ****Helpfulness**:** The response is scattered and doesn't maintain a clear focus. It jumps from one topic to another without depth.
- ****Relevance**:** While it touches on music and personal questions, it doesn't provide meaningful engagement.
- ****Clarity**:** The sentences are choppy and lack fluidity, making it hard to follow.
- ****Score**:** 3/10

****Assistant 2**:**

- ****Helpfulness**:** This response also lacks coherence and jumps between topics, but it does mention a profession, which adds some context.
- ****Relevance**:** It includes some relevant information about work and living situation, but it feels repetitive and unfocused.
- ****Clarity**:** Similar issues with sentence structure and flow as Assistant 1.
- ****Score**:** 4/10

In summary, both responses need significant improvement in coherence and relevance. I would suggest a score of 3 for Assistant 1 and 4 for Assistant 2, as the latter provides slightly more context. However, both could benefit from a more structured and engaging approach.

02/09/2025 22:00:56 - INFO - httpx - HTTP Request: POST
https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 22:00:56 - INFO - httpx - HTTP Request: POST
https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 22:00:56 - INFO - root - General Public: It seems like your message didn't come through. If you have any further questions or need additional feedback, feel free to share!
02/09/2025 22:00:56 - INFO - root - Critic: It seems there was no additional input or question. If you have any further thoughts or need clarification on the evaluations of the assistants, feel free to share! I'm here to help.
02/09/2025 22:00:59 - INFO - httpx - HTTP Request: POST
https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 22:00:59 - INFO - httpx - HTTP Request: POST
https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 22:00:59 - INFO - root - General Public: Evaluation evidence: In evaluating the responses from both assistants, I noted that Assistant 1's reply was disorganized and included irrelevant comments, which detracted from its overall helpfulness and coherence. It lacked a clear structure and did not effectively engage with the user's question. On the other hand, Assistant 2 provided a more coherent response, mentioning their profession and living situation, although it still suffered from some repetition and lack of clarity. Overall, Assistant 2's response was more relevant and informative, leading to a higher score.

The score of Assistant 1: 3

The score of Assistant 2: 5

02/09/2025 22:00:59 - INFO - root - Critic: Evaluation evidence: Upon reviewing both responses, Assistant 1's answer is fragmented and lacks coherence, with abrupt topic shifts and irrelevant comments that detract from the overall quality. In contrast, Assistant 2, while also somewhat disjointed, provides a clearer narrative about their work and living situation, making it slightly more relevant and helpful. However, both responses could benefit from improved structure and focus.

The score of Assistant 1: 3

The score of Assistant 2: 5

02/09/2025 22:01:02 - INFO - httpx - HTTP Request: POST
https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 22:01:02 - INFO - httpx - HTTP Request: POST
https://api.openai.com/v1/chat/completions "HTTP/1.1 200 OK"
02/09/2025 22:01:02 - INFO - root - General Public: Evaluation evidence: In evaluating the responses, Assistant 1's answer is characterized by a lack of coherence and relevance. It jumps between topics without providing meaningful engagement or depth, making it difficult to follow. The inclusion of irrelevant comments, such as "Wow you are sexy," detracts from the overall quality. On the other hand, Assistant 2, while still somewhat disjointed, offers a more structured response that includes information about their profession and living situation. This makes it slightly more relevant and informative, despite some repetition and lack of clarity. Overall, Assistant 2's response is more helpful and engaging than Assistant 1's.

The score of Assistant 1: 3

The score of Assistant 2: 6

02/09/2025 22:01:02 - INFO - root - Critic: Evaluation evidence: In evaluating the responses, Assistant 1's answer is characterized by a lack of coherence and relevance. It jumps between topics without providing meaningful engagement or depth, making it difficult to follow. The inclusion of irrelevant comments, such as "Wow you are sexy," detracts from the overall quality. On the other hand, Assistant 2 offers a more structured response, mentioning their profession and living situation, which adds context. However, it still suffers from some repetition and a lack of clarity. Overall, Assistant 2's response is more relevant and informative, leading to a higher score.

The score of Assistant 1: 3

The score of Assistant 2: 6

References

- [1] C.-M. Chan *et al.*, *Chateval: Towards better llm-based evaluators through multi-agent debate*, 2023. arXiv: 2308.07201 [cs.CL].
- [2] *Chateval: A benchmark evaluation framework for chatbots*, <https://github.com/ludovic4g/ChatEval>, Accessed: 2025-02-12, 2025.
- [3] *Gpt4all*, <https://github.com/selfsff/GPT4ALL-Free-GPT-API>, Accessed: 2025-02-12, 2024.